

NetConfigQA2.0: 네트워크 설정 해석 능력 평가를 위한 질의응답 벤치마크

KICS 2026

2026.02.06.

박유진¹, 이현정¹, 김기현², 박찬진²,
박진영³, 김태훈¹, 박천음^{1*}

¹ 국립한밭대학교

² 한국과학기술정보연구원 (KISTI)

³ 성균관대학교

Outline

1. Introduction
2. Proposed Method
(NetConfigQA2.0)
3. Experiments
4. Conclusion

Introduction

Proposed Method

Experiments

Conclusion

Introduction

“우리 네트워크를 LLM 이 얼마나 잘 이해하는가?”

관점	설명	기존 벤치마크
도메인 지식	3GPP 표준, 라우팅 프로토콜 등 일반 지식	TeleQnA, TeleQuAD, Netbench ... 등
특정 토폴로지 이해	특정 네트워크 환경의 구성과 동작을 파악	미비

한계점

1. 토폴로지의 해석에 관한 연구는 상대적으로 미비
2. 선행 연구에서 정적 분석에 한정되는 한계 존재

선행 연구 (NetConfigQA 1.0)

- 기존 연구 (NetConfEval, NeMoEval...) 는 대부분 구성을 만드는 것에 초점
- 실제 운영 : 이미 배포된 수많은 설정을 해석하고 검증하는 “해석 중심 접근 방식 ”

=> 해서 주시 진이으다으 스택하느 NetConfigQA 1.0

벤치마크	주요 목표	입출력	데이터 생성	평가 방식	토폴로지 특화
NetConfEval [1]	설정 · 코드 생성	요구→설정/코드/API	반자동	정답 일치	X
NETPRESS [5]	에이전트 운영	지시→액션	자동	정확 · 안전 · 지연	△
NETLLMBENCH [6]	명령 생성	지시→JSON(단일)	수동	에뮬레이터 검증	△
NeMoEval [2]	토폴로지 분석코드	질의→그래프코드	수동	실행결과 정확	X
NetConfigQA (Ours)	설정 해석 · QA	네트워크 설정→질문, 답	반자동	정답 일치	O

한계점

1. 토폴로지의 해석에 관한 연구는 상대적으로 미비
2. 선행 연구에서 정적 분석에 한정되는 한계 등 존재

항목	기존 한계	NetConfigQA2.0 목표
도달성 분석	경로 정보 없음	실제 패킷 경로 (Traceroute) 정답 제공
장애 시뮬레이션	추론 불가	링크 / 노드 다운 시 네트워크 변화 분석
평가 기준	텍스트 유사도	논리적 정확성 (TA-Acc) 기반 평가
범용성	특정 토폴로지 종속	다양한 Config 에도 적용 가능한 파이프라인

Introduction

Proposed Method

Experiments

Conclusion

Proposed Method

핵심 특징

1. PnetLab & Batfish 기반 정답 생성


a. 실제 장비 동작을 모델링



네트워크 장비를 가상으로
구성하고 실습할 수 있는 플랫폼



네트워크 설정을 분석,
논리적으로 시뮬레이션하여
동작을 검증하는 네트워크 분석
도구



핵심 특징

2. 5 단계 난이도 체계

a. L1(조회) - L5(장애추론)

Level	속성	설명	평가 요소	핵심 키워드
L1	Fact	장비에 있는 그대로 무엇이 적혀있는가?	Config 파싱	Hostname, IP, NTP
L2	Stats	네트워크 전체 통계는 어떠한가?	정보 수집/집계	"몇 개?", "목록"
L3	Logic	설정 간에 오류가 없는가?	관계 비교/분석	iBGP, VRF, L2VPN
L4	Flow	패킷을 보내면 실제로 도착하는가?	경로 시뮬레이션	Traceroute, Loop
L5	Impact	장애가 나면 어떻게 되는가?	장애 영향 예측	Link Failure

핵심 특징


2. 5 단계 난이도 체계

a. L1: 단일 장비 설정 조회 (Hostname, IP, VRF 등)

L1

Q: pe1 장비의 호스트네임은 무엇입니까 ?

A: pe1



핵심 특징


2. 5 단계 난이도 체계

a. L2: 단일 장비 설정 집계 (SSH 활성화, OSPF Area 등)

L2

Q: ssh 접속이 가능한 장비 목록을 알려주세요 .

A: ["leaf1", "leaf2", ...]




핵심 특징

2. 5 단계 난이도 체계

- a. L3: 장비 간 설정 정합성 검증 (iBGP Mesh, L2VPN 등)

L3

Q: VRF_AI VRF 를 사용하는 장비 목록을 알려주세요
A: ["pe1", "pe2"]



핵심 특징


2. 5 단계 난이도 체계

a. L4: 동적 패킷 도달성 분석 (Trace, Reachability)

L4

Q: pe2 에서 10.0.1.1 까지의 네트워크 경로
(장비 순서) 를 나열해주세요 .

A: pe2 -> p3 -> p2 -> pe1



핵심 특징


2. 5 단계 난이도 체계

a. L5: 장애 시나리오 기반 추론 (Link Failure Impact)

L5

Q: P4 에서 Leaf3 로의 통신이 실패할 때 ,
어느 장비에서 차단됩니까 ?


A: P4(Routing Table 에 Leaf4 없음)



핵심 특징

3. 자동화된 파이프라인

a. Config 파일만으로 벤치마크 생성



핵심 특징

3. 자동화된 파이프라인


a. Config 파일만으로 벤치마크 생성



네트워크 장비를 자동으로 설정하고
관리하는 네트워크 자동화 플랫폼

- 1** PnetLab 네트워크 장비
config(장비 설정 파일)
수집

```
!  
!  
interface GigabitEthernet0/0  
ip address 172.16.1.2 255.255.255.0  
duplex auto  
speed auto  
media-type rj45  
!
```



핵심 특징

3. 자동화된 파이프라인


a. Config 파일만으로 벤치마크 생성

2

batfish 분석 (Control Plane 및 Data Plane 모델링)

- 네트워크를 분석하고 Config 를 파싱하여 Structured Configs Data 생성

```
"interfaces": [  
  {  
    "name": "GigabitEthernet0/0",  
    "ipv4": "172.16.1.2/24",  
    "vlan": null,  
    "vrf": null,  
    "status": "up"  
  },  
]
```




핵심 특징

3. 자동화된 파이프라인

a. Config 파일만으로 벤치마크 생성

3 126 개 질문 패턴과 Structured Configs Data 매핑 → 질문 생성

```
{
  "traceroute_path": {
    "level": "L4",
    "category": "Reachability_Analysis",
    "answer_type": "text",
    "template": "{src_node}에서 {dst_node}({dst_ip})로 가는 패킷의 경로는?",
    "verification": "Batfish traceroute 결과와 비교"
  }
}
```





핵심 특징

3. 자동화된 파이프라인

3 L1 ~ L3: 정적분석 문제 정답 계산

- 구조화된 Structured Configs Data에서 정답을 직접 조회하거나 계산.





핵심 특징

3. 자동화된 파이프라인

3 L4 ~ L5: 동적 분석 문제 정답 계산

- Batfish Simulation

- 장비 설정을 분석하여 Data Plane 을 모델링하고 ,
패킷의 흐름을 논리적으로 시뮬레이션하여 정답 계산




핵심 특징

3. 자동화된 파이프라인

a. Config 파일만으로 벤치마크 생성

4 최종 데이터셋 생성

```
{  
  "id": "TRACEROUTE_pe1_p3",  
  "category": "Reachability_Analysis",  
  "level": "L4",  
  "question": "pe1에서 10.0.0.3까지의 네트워크 경로(장비 순서)를 나열해주세요.",  
  "answer_status": "OK",  
  "answer_type": "text",  
  "answer": "\"pe1 → p2 → p3\"",  
}
```



Introduction

Proposed Method

Experiments

Conclusion

Experiments

실험 환경

- 노드 구성 : **10 nodes**



- Leaf Switch (4): 최상단 고객 접점 (Leaf1-4)




- PE Router (2): VRF 기반 네트워크 격리



- P Router (4): MPLS Core Backbone

- 네트워크 구성

- 표준 MPLS L3VPN 구조
- OSPF, MP-BGP, LDP 프로토콜 연동



Experiments

1. NetConfigQA2.0 데이터셋 (Ours)

Level	Description	Count
L1	단일 장비 설정 조회 (Hostname, IP, VRF 등)	364
L2	복수 장비 설정 집계 (SSH 활성화, OSPF Area 등)	21
L3	장비 간 설정 정합성 검증 (iBGP Mesh, L2VPN 등)	127
L4	동적 패킷 도달성 분석 (Trace, Reachability)	149
L5	장애 시나리오 기반 추론 (Link Failure Impact)	101
Total Questions		762

Answer Type	Count	Percentage
map	40	5.2%
numeric	168	22.2%
set	162	21.3%
text	392	51.4%
Total	762	100%

- 네트워크 장비 10 개 기준 , 장비 수가 많아지면 데이터셋 문제 수도 비례하여 증가
- Metric: TA-Acc(Type-Aware Accuray), Rouge-L, BERTScore, EM, F1(Token)

Experiments

1. NetConfigQA2.0 데이터셋 (Ours)

Type	데이터 예시
Set (List)	<code>["p1", "p2", "p3"]</code> (순서 없는 라우터 목록)
Map (JSON)	<code>{"Gi0/0": "up", "Gi0/1": "down"}</code> (인터페이스 상태)
Numeric	<code>5, 100</code> (OSPF Cost, 개수)
Text	<code>pe1, p1 → p2 → p3, Disabled, 경로 없음</code> (호스트명, 설정 상태)

- 하나의 메트릭 (EM, F1) 을 일괄적으로 적용하면 **정확한 평가가 어려움**
- 네트워크 특성상 정확한 값이 중요, 유사한 답에 점수를 주면 **평가가 정확하지 않음**
- NetConfigQA2.0 데이터셋을 정확히 평가하기 위해서
 - 데이터의 타입 (Answer Type) 을 먼저 식별하고,
 - 각 타입에 가장 적합한 평가 로직을 동적으로 적용하는 방법 (Type-Aware Accuracy) 을 사용

1. NetConfigQA2.0 데이터셋 (Ours) - Type-Aware Accuracy

● Set 타입

- 순서를 무시하고 구성 요소만 비교, 일부만 맞을 경우 **Precision/Recall 기반 F1 Score**로 부분 점수를 부여
- **정답**: ["GigabitEthernet0/0", "GigabitEthernet0/1", "Loopback0"] (3개)

예시 답변	채점 방식	점수	판정 이유
["Loopback0", "Gi0/0", "Gi0/1"]	Set F1	1.0	순서가 바뀌었지만 구성 요소 일치
["Gi0/0", "Gi0/1"]	Set F1	0.8	3개 중 2개 맞춤 (Recall 0.67 반영)
["Loopback0", "Gi0/0", "Gi0/1"]	Exact Match	0.0	문자열 순서 다름

● Numeric 타입

- 정규식을 사용하여 텍스트에서 **숫자 값만 추출**하고 **수치적으로 비교**하여 일치 여부를 판단

1. NetConfigQA2.0 데이터셋 (Ours) - Type-Aware Accuracy

● Map 타입

- JSON 을 파싱하여 Key 일치도 (50%) 와 Value 일치도 (50%) 를 합산하여 계산
- 모델이 정보를 얼마나 유실 없이 찾아냈는지와 찾아낸 정보가 얼마나 정확한지를 동시에 반영
- Value 비교 시 **IP 주소는 CIDR 을 제거**하고 , 상태값 (shutdown → down) 을 정규화하여 의미적 일치를 판단
- **정답** : {"Gi0/0": "172.16.2.2/24", "Gi0/1": "", "Gi0/2": "10.10.2.1/24", "Gi0/3": "10.10.10.32/24"} (4 개)

예시 답변	점수 v	판정 이유
<code>{"Gi0/0": "172.16.2.2", ...}</code> (4개)	1.0	<code>172.16.2.2/24 == 172.16.2.2</code> (CIDR 무시)
<code>{"Gi0/0": "172.16.2.2", "Gi0/2": "10.10.2.1"}</code>	0.75	Key 2/4($50\% \times 0.5 = 0.25$) + Value 2/2($100\% \times 0.5 = 0.5$)
<code>{"Gi0/0": "172.16.2.3/24"}</code>	0.0	IP 주소 값 불일치 (<code>.2</code> vs <code>.3</code>)

1. NetConfigQA2.0 데이터셋 (Ours) - Type-Aware Accuracy

● Text 타입

- 먼저 LLM 의 지저분한 출력에서 핵심 답변을 추출 (Parsing) 하고 , 추출된 답변을 정규화된 **Exact Match** 로 1 차 평가한 후 , 실패 시 **Token F1** 로 부분 점수를 부여합니다 .
- 질문 : "pe1 에서 10.0.0.1 까지의 경로를 나열해주세요 ."
- 정답 (Gold): "pe1 → p2"
- 원본 LLM 출력 (raw_pred): "<think> 분석 ...</think>PE1→P2"
- Parsing: <think> 태그 , 서술어 제거 → "**PE1→P2**"

파싱 후 답변	채점 방식	점수	판정 이유
"PE1→P2"	Normalized EM	1.0	대소문자 정규화 (PE1 == pe1)
"pe1 -> p2"	Normalized EM	1.0	화살표 정규화 (-> == →)

2. 기존 통신 도메인 벤치마크 데이터셋

- **TeleQnA - Telecom Standards Knowledge Benchmark**
 - 데이터 출처 : 3GPP, IEEE 표준 문서 및 연구 논문 (Research Papers)
 - 규모 : 10,000 Questions
 - 형식 : Multiple Choice Questions (객관식 5 지 선택)
 - 평가 지표 : Accuracy (정답 선택 여부)

```
"question 0": {  
  "question": "What is the purpose of the Nmfaf_3daDataManagement_Deconfigure service operation? [3GPP Release 18]",  
  "option 1": "To configure the MFAF to map data or analytics received by the MFAF to out-bound notification endpoints",  
  "option 2": "To configure the MFAF to stop mapping data or analytics received by the MFAF to out-bound notification endpoints",  
  "option 3": "To supply data or analytics from the MFAF to notification endpoints",  
  "option 4": "To fetch data or analytics from the MFAF based on fetch instructions",  
  "answer": "option 2: To configure the MFAF to stop mapping data or analytics received by the MFAF to out-bound notification endpoints",  
  "explanation": "The Nmfaf_3daDataManagement_Deconfigure service operation is used to stop mapping data or analytics received by the M",  
  "category": "Standards specifications"  
},
```

2. 기존 통신 도메인 벤치마크 데이터셋

- **NetBench - Descriptive Scenario Analysis**

- 데이터 출처 : 통신사 / 벤더 SME(전문가) 및 Digital Twin 시뮬레이션
- 규모 : 5,390 QA Pairs
- 형식 : Descriptive QA (서술형 답변) 및 Text Generation
- 평가 지표 : BERTScore (Text Similarity)
- 설명 능력을 평가

- **TeleQuAD - RAG & Information Extraction**

- 데이터 출처 : 3GPP Technical Specifications (TS 시리즈)
- 규모 : 약 4,500 QA Pairs
- 형식 : Extractive QA (SQuAD Style) - 지문에서 정답 구간 추출 , 문서 내 텍스트 찾기
- 평가 지표 : BERTScore
- 매뉴얼 검색 능력에 집중

실험 결과 1

- 통신 도메인 벤치마크에서의 LLM 성능 비교
- 모든 벤치마크에서 전반적으로 모델 간 성능 차이는 크지 않음
- TeleQnA(**0.032**), TeleQuAD(**0.019**), NetBench(**0.032**)

Model	TeleQnA (Accuracy)	TeleQuAD (BERTScore)	NetBench (BERTScore)	Average (Norm.)
GPT-4o-mini	0.743	0.824	0.720	0.762
Llama3.1-8B	0.664	0.851	0.798	0.771
Mistral3-8B	0.706	0.866	0.790	0.787
Qwen3-8B	0.733	0.867	0.799	0.800
GPT-OSS-20B	0.757	0.876	0.808	0.814

실험 결과 2

- NetConfigQA2.0 에서의 LLM 성능 비교
 - 네트워크 설정 기반 추론 능력을 효과적으로 분석 가능

Model	Rouge-L	BERTScore	EM	F1(Token)	TA-Acc
GPT-4o-mini	0.155	0.942	0.398	0.539	0.515
Llama-3.1-8B	0.314	0.897	0.176	0.302	0.291
Mistral3-8B	0.279	0.875	0.201	0.304	0.416
Qwen3-8B	0.414	0.932	0.339	0.472	0.465
GPT-OSS-20B	0.439	0.942	0.437	0.529	0.612

실험 결과 3

- NetConfigQA2.0 난이도별 (L1-L5) 성능 비교 (TA-Acc)
 - LLM 이 단순한 설정 요소에 대한 이해도는 갖추었으나 ,
 - 네트워크 전체적인 상태를 논리적으로 추론하는 데 한계 존재

Model	L1	L2	L3	L4	L5
GPT-4o-mini	0.765	0.541	0.369	0.267	0.159
Llama-3.1-8B	0.368	0.371	0.305	0.184	0.138
Mistral3-8B	0.572	0.143	0.500	0.158	0.183
Qwen3-8B	0.639	0.294	0.431	0.256	0.225
GPT-OSS-20B	0.873	0.873	0.605	0.266	0.134

Level	Description
L1	단일 장비 설정 조회 (Hostname, IP, VRF 등)
L2	복수 장비 설정 집계 (SSH 활성화, OSPF Area 등)
L3	장비 간 설정 정합성 검증 (iBGP Mesh, L2VPN 등)
L4	동적 패킷 도달성 분석 (Trace, Reachability)
L5	장애 시나리오 기반 추론 (Link Failure Impact)

Introduction

Proposed Method

Experiments

Conclusion

Conclusion

Conclusion

- NetConfigQA2.0
 - LLM 의 네트워크 지식을 평가하는 데 변별력 있는 벤치마크
- LLM 이 전반적인 네트워크 추론에는 한계가 있음을 확인
- 향후 연구
 - Batfish, Cisco NSO 를 결합한 Multi-Agent System 을 도입
 - LLM 이 Pnetlab 기반 실험실 제어

Thank you

Lee Hyeonjeong

leehj@edu.hanbat.ac.kr
<https://nlp.hanbat.ac.kr/>

핵심 특징

2. 5 단계 난이도 체계

a. L1(조회) - L5(장애추론)

Level	속성	설명	
L1	Fact (사실 조회)	장비 속성에 있는 그대로 무엇이 적혀있는가?	Q: ...은 무엇입니까 ?
L2	Stats (현황 집계)	네트워크 전체 통계는 어떠한가?	
L3	Logic (정합성)	설정 간에 오류가 없는가?	
L4	Flow (동작 예측)	패킷을 보내면 실제로 도착하는가?	
L5	Impact (장애 대응)	만약(What-If) 장애가 나면 어떻게 되는가?	Q: ... 목록을 알려주세요 . A: ["f1", "f2", ...]

Level	Description	Count
L1	단일 장비 설정 조회 (Hostname, IP, VRF 등)	364
L2	복수 장비 설정 집계 (SSH 활성화, OSPF Area 등)	21
L3	장비 간 설정 정합성 검증 (iBGP Mesh, L2VPN 등)	127
L4	동적 패킷 도달성 분석 (Trace, Reachability)	149
L5	장애 시나리오 기반 추론 (Link Failure Impact)	101
Total Questions		762

L3

Q: VRF_AI VRF 를 사용하는 장비 목록을 알려주세요
A: ["pe1", "pe2", ...]

L4

Q: pe2 에서 10.0.1.1 까지의 네트워크 경로 (장비
순서) 를 나열해주세요 .
A: pe2 -> p3 -> p2 -> pe2

L5

Q: pe2 에서 leaf3 으로 의 통신이 실패할 때 , 어느
장비에서 차단되니까 ?
A: pe2