

NetConfigQA2.0: 네트워크 설정 해석 능력 평가를 위한 질의응답 벤치마크

KICS 2026

2026.02.06.

박유진¹, 이현정¹, 김기현², 박찬진²,
박진영³, 김태훈¹, 박천음^{1*}

¹국립한밭대학교

²한국과학기술정보연구원(KISTI)

³성균관대학교

Outline

1. Introduction
2. Proposed Method
(NetConfigQA2.0)
3. Experiments
4. Conclusion

Introduction

Proposed Method

Experiments

Conclusion

Introduction

“우리 네트워크를 LLM이 얼마나 잘 이해하는가?”

관점	설명	기존 벤치마크
도메인 지식	3GPP 표준, 라우팅 프로토콜 등 일반 지식	TeleQnA, TeleQuAD, Netbench ...등
특정 토폴로지 이해	특정 네트워크 환경의 구성과 동작을 파악	미비

한계점

1. 토폴로지의 해석에 관한 연구는 상대적으로 미비
2. 선행 연구에서 정적 분석에 한정되는 한계 존재

선행 연구 (NetConfigQA 1.0)

- 기존 연구(NetConfEval, NeMoEval...)는 대부분 구성을 만드는 것에 초점
- 실제 운영: 이미 배포된 수많은 설정을 해석하고 검증하는 “해석 중심 접근 방식”

=> 해석 중심 질의응답을 수행하는 **NetConfigQA 1.0**

벤치마크	주요 목표	입출력	데이터 생성	평가 방식	토폴로지 특화
NetConfEval [1]	설정 · 코드 생성	요구→설정/코드/API	반자동	정답 일치	X
NETPRESS [5]	에이전트 운영	지시→액션	자동	정확 · 안전 · 지연	△
NETLLMBENCH [6]	명령 생성	지시→JSON(단일)	수동	에뮬레이터 검증	△
NeMoEval [2]	토폴로지 분석코드	질의→그래프코드	수동	실행결과 정확	X
NetConfigQA (Ours)	설정 해석 · QA	네트워크 설정→질문, 답	반자동	정답 일치	O

한계점

1. 토폴로지의 해석에 관한 연구는 상대적으로 미비
2. 선행 연구에서 정적 분석에 한정되는 한계 등 존재

항목	기존 한계	NetConfigQA2.0 목표
도달성 분석	경로 정보 없음	실제 패킷 경로 (Traceroute) 정답 제공
장애 시뮬레이션	추론 불가	링크/노드 다운 시 네트워크 변화 분석
평가 기준	텍스트 유사도	논리적 정확성 (TA-Acc) 기반 평가
범용성	특정 토폴로지 종속	다양한 Config 에도 적용 가능한 파이프라인

Introduction

Proposed Method

Experiments

Conclusion

Proposed Method

핵심 특징

1. PnetLab & Batfish 기반 정답 생성


a. 실제 장비 동작을 모델링



네트워크 장비를 가상으로
구성하고 실습할 수 있는
플랫폼



네트워크 설정을 분석해서
네트워크의 실제 동작을
검증하는 네트워크 분석 도구



핵심 특징

2. 5단계 난이도 체계

a. L1(조회) - L5(장애추론)

Level	Description	Count
L1	단일 장비 설정 조회 (Hostname, IP, VRF 등)	364
L2	복수 장비 설정 집계 (SSH 활성화, OSPF Area 등)	21
L3	장비 간 설정 정합성 검증 (iBGP Mesh, L2VPN 등)	127
L4	동적 패킷 도달성 분석 (Trace, Reachability)	149
L5	장애 시나리오 기반 추론 (Link Failure Impact)	101
Total Questions		762

L1

Q: pe1 장비의 호스트네임은 무엇입니까?

A: pe1

L2

Q: ssh 접속이 가능한 장비 목록을 알려주세요.

A: ["leaf1", "leaf2", ...]

L3

Q: VRF_AI VRF를 사용하는 장비 목록을 알려주세요

A: ["pe1", "pe2", ...]

L4

Q: pe2에서 10.0.1.1까지의 네트워크 경로(장비 순서)를 나열해주세요.

A: pe2 -> p3 -> p2 -> pe2

L5

Q: pe2에서 leaf3으로 의 통신이 실패할 때, 어느 장비에서 차단됩니까?

A: pe2

핵심 특징


2. 5단계 난이도 체계

- a. L1: 단일 장비 설정 조회(Hostname, IP, VRF 등)

L1

Q: pe1 장비의 호스트네임은 무엇입니까?

A: pe1




핵심 특징

2. 5단계 난이도 체계

- a. L2: 단일 장비 설정 집계 (SSH 활성화, OSPF Area 등)

L2

Q: ssh 접속이 가능한 장비 목록을 알려주세요.
A: ["leaf1", "leaf2", ...]




핵심 특징

2. 5단계 난이도 체계

a. L3: 장비 간 설정 정합성 검증 (iBGP Mesh, L2VPN 등)

L3

Q: VRF_AI VRF를 사용하는 장비 목록을 알려주세요
A: ["pe1", "pe2", ...]



핵심 특징


2. 5단계 난이도 체계

a. L4: 동적 패킷 도달성 분석(Trace, Reachability)

L4

Q: pe2에서 10.0.1.1까지의 네트워크 경로(장비 순서)를 나열해주세요.

A: pe2 -> p3 -> p2 -> pe1



핵심 특징


2. 5단계 난이도 체계

a. L5: 장애 시나리오 기반 추론 (Link Failure Impact)

L5

Q: pe2에서 leaf3으로 의 통신이 실패할 때, 어느 장비에서 차단됩니까?

A: pe2



핵심 특징

2. 5단계 난이도 체계


a. 질문 설계 기준

속성	설명	출처	레벨
Reachability	A에서 B로 트래픽 도달 가능	HSA, VeriFlow, Batfish	L4
Loop-freedom	포워딩 루프 없음	HSA, VeriFlow	L4
Isolation	VRF/테넌트 간 트래픽 격리	Minesweeper, Config2Spec	L3, L4
Waypointing	특정 노드 반드시 통과	Minesweeper	L4
Fault Tolerance	장애 시에도 도달성 유지	Minesweeper, DNA	L5
Differential Reachability	변경 전/후 도달성 차이	DNA (NSDI'22)	L5

핵심 특징

3. 자동화된 파이프라인

a. Config 파일만으로 벤치마크 생성



핵심 특징


3. 자동화된 파이프라인

a. Config 파일만으로 벤치마크 생성

- 1 config(장비 설정 파일) 수집



네트워크 장비를
자동으로 설정하고
관리하는 네트워크
자동화 플랫폼




핵심 특징

3. 자동화된 파이프라인

a. Config 파일만으로 벤치마크 생성

2 batfish 분석 (Control Plane 및 Data Plane 모델링)

- batfish의 시뮬레이션 기능으로 추론 및 분석 문제의 정답 생성



핵심 특징


3. 자동화된 파이프라인

a. Config 파일만으로 벤치마크 생성

3 126개 질문 패턴에
시뮬레이션 결과
매핑

4 QA 생성

```
{
  "traceroute_path": {
    "level": "L4",
    "category": "Reachability_Analysis",
    "answer_type": "text",
    "template": "{src_node}에서 {dst_node}({dst_ip})로 가는 패킷의 경로는?",
    "verification": "Batfish traceroute 결과와 비교"
  }
}
```



Introduction

Proposed Method

Experiments

Conclusion

Experiments

Experiments

실험 환경

- 노드 구성


-  Leaf Switch (4): 최상단 고객 접점(Leaf1-4)

-  PE Router (2): VRF 기반 네트워크 격리

-  P Router (4): MPLS Core Backbone

- 핵심 기술

- 표준 MPLS L3VPN 구조
- OSPF, MP-BGP, LDP 프로토콜 연동



데이터셋

- NetConfigQA2.0
 - 762 Question & Answer (Negative 185개 포함)
 - **TA-Acc(Type-Aware Accuray)**, Rouge-L, BERTScore, EM, F1(Token),

"question": "...",
"answer": "...",
"answer_type": ""



Type	Count	비율	평가 로직	예시
Text	392	51.4%	정규화 후 Exact Match	"PE1" = "pe1" ✓
Set	162	21.3%	숫자 파싱 후 비교	"3개" = 3 ✓
Numeric	101	13.3%	순서 무시, 집합 F1	{A,B,C} = {C,A,B} ✓
Number	67	8.8%	Key-Value 쌍별 F1	{"a":1, "b":2} 부분 일치 가능
Map	40	5.2%	홀 순서 일치 확인	$A \rightarrow B \rightarrow C \neq A \rightarrow C \rightarrow B$ ✗

데이터셋


- 기존 통신 도메인 벤치마크

데이터셋	문항 수	형식	데이터 출처	평가 지표
TeleQnA	10,000	객관식 (MCQ)	3GPP/IEEE 표준	Accuracy
TeleQuAD	4,485	추출형 QA	3GPP 문서	BERTScore
NetBench	5,390	서술형 QA	Digital Twin	BERTScore
NetConfigQA2.0	762	구조화 QA	실제 Config	TA-Acc

데이터셋

- TA-Acc(Type-Aware Accuray)

$$\text{TA-Acc} = \frac{1}{N} \sum_{i=1}^N s(p_i, g_i | t_i)$$
$$s(\cdot) = \begin{cases} \text{F1}_{\text{set/map}} & (t_i \in \text{Struct}) \\ \text{EM}_{\text{norm}} & (\text{otherwise}) \end{cases}$$



순서가 없음, 부분 점수
set: ["a", "b"] == ["b", "a"]
map: {VRF_AI: 65000:1, VRF_BIO: 65000:2, VRF_HPC: 65000:3}

실험 결과 1

- 통신 도메인 벤치마크에서의 LLM 성능 비교
- 모든 벤치마크에서 전반적으로 모델 간 성능 차이는 크지 않음
- TeleQnA(**0.032**), TeleQuAD(**0.019**), NetBench(**0.032**)

Model	TeleQnA (Accuracy)	TeleQuAD (BERTScore)	NetBench (BERTScore)	Average (Norm.)
GPT-4o-mini	0.743	0.824	0.720	0.762
Llama3.1-8B	0.664	0.851	0.798	0.771
Mistral3-8B	0.706	0.866	0.790	0.787
Qwen3-8B	0.733	0.867	0.799	0.800
GPT-OSS-20B	0.757	0.876	0.808	0.814

실험 결과 2

- NetConfigQA2.0에서의 LLM 성능 비교
 - 네트워크 설정 기반 추론 능력을 효과적으로 분석 가능

Model	Rouge-L	BERTScore	EM	F1(Token)	TA-Acc
GPT-4o-mini	0.155	0.942	0.398	0.539	0.515
Llama-3.1-8B	0.314	0.897	0.176	0.302	0.291
Mistral3-8B	0.279	0.875	0.201	0.304	0.416
Qwen3-8B	0.414	0.932	0.339	0.472	0.465
GPT-OSS-20B	0.439	0.942	0.437	0.529	0.612

실험 결과 3

- NetConfigQA2.0 난이도별(L1-L5) 성능 비교 (TA-Acc)
 - LLM이 단순한 설정 요소에 대한 이해도는 갖추었으나,
 - 네트워크 전체적인 상태를 논리적으로 추론하는 데 한계 존재

Model	L1	L2	L3	L4	L5
GPT-4o-mini	0.765	0.541	0.369	0.267	0.159
Llama-3.1-8B	0.368	0.371	0.305	0.184	0.138
Mistral3-8B	0.572	0.143	0.500	0.158	0.183
Qwen3-8B	0.639	0.294	0.431	0.256	0.225
GPT-OSS-20B	0.873	0.873	0.605	0.266	0.134

Level	Description
L1	단일 장비 설정 조회 (Hostname, IP, VRF 등)
L2	복수 장비 설정 집계 (SSH 활성화, OSPF Area 등)
L3	장비 간 설정 정합성 검증 (iBGP Mesh, L2VPN 등)
L4	동적 패킷 도달성 분석 (Trace, Reachability)
L5	장애 시나리오 기반 추론 (Link Failure Impact)

Introduction

Proposed Method

Experiments

Conclusion

Conclusion

Conclusion

- NetConfigQA2.0
 - LLM의 네트워크 지식을 평가하는 데 변별력 있는 벤치마크
- LLM이 전반적인 네트워크 추론에는 한계가 있음을 확인

Conclusion

- 향후 연구
 - Batfish, Cisco NSO를 결합한 Multi-Agent System을 도입
 - LLM이 Pnetlab 기반 실험실 제어

Thank you

Lee Hyeonjeong

leehj@edu.hanbat.ac.kr
<https://nlp.hanbat.ac.kr/>